SCH 순천향대학교

노크 위치 탐지를 위한 기계학습 모델 연구

A study on machine learning models for knock position detection

2023 / 05 / 25

2 조 IPSM

순천향대학교 기계공학과

3095069@naver.com

20194523 정승호
20184514 주성덕
20184553 박혁수
20184503 김영혁
20184510 조세진
20204618 오강바야르

Contents

1. 연구 배경 및 목적

- 연구 배경
- 연구 목표

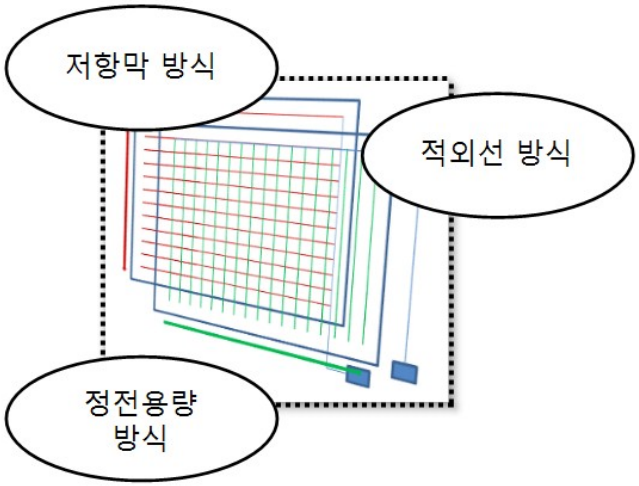
2. 실험 방법

- 실험 장비 소개
- 데이터 추출
- 데이터 전처리
- 기계학습

3. 연구 결과

- 실험 결과
- 결론

1. 연구 배경 및 목적



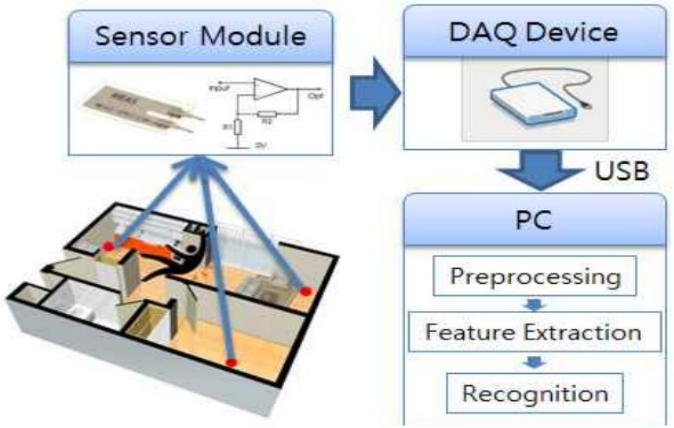
기존 위치 탐지 방식의 단점 :

표면 처리가 필요 , 넓은 면적에서의 비용 증가

장애물이 존재할 경우 탐지의 어려움

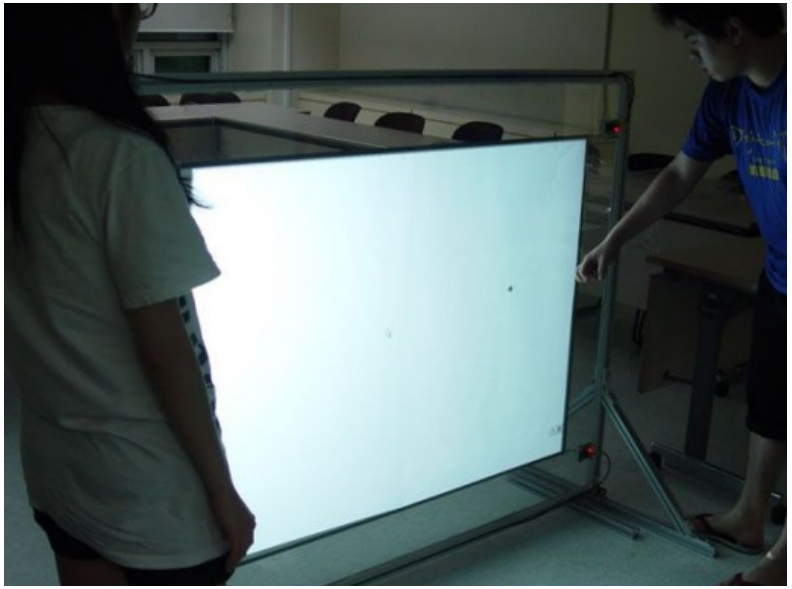
새로운 방식의 위치 탐지를 위해 진동을 사용하는 연구가 활발히 진행 되고 있음

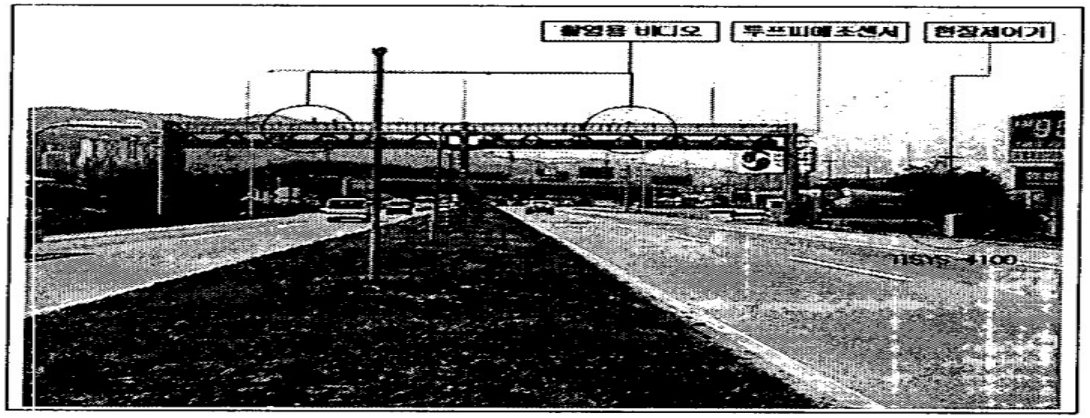


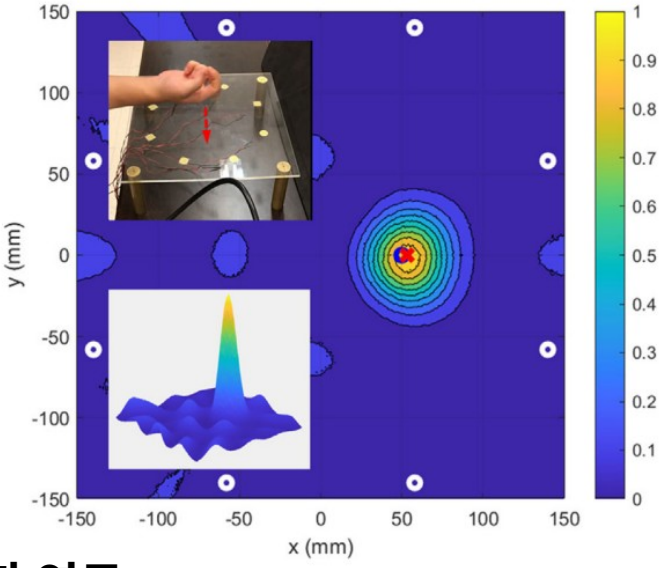


1. 연구 배경



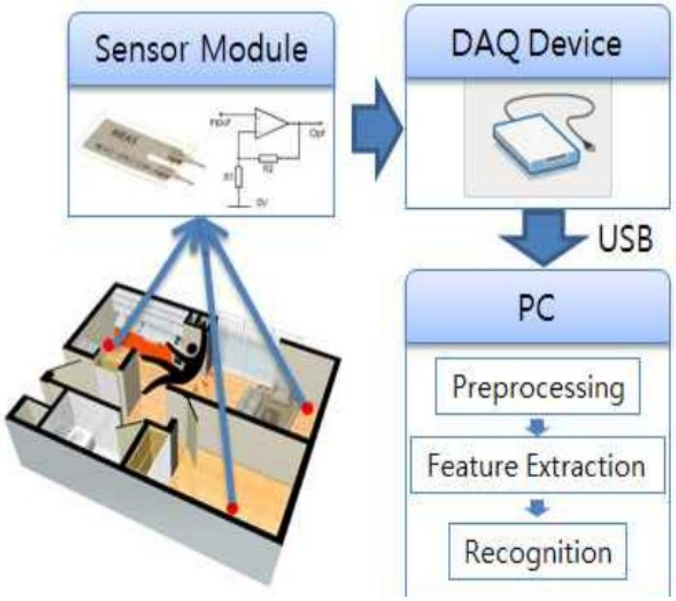




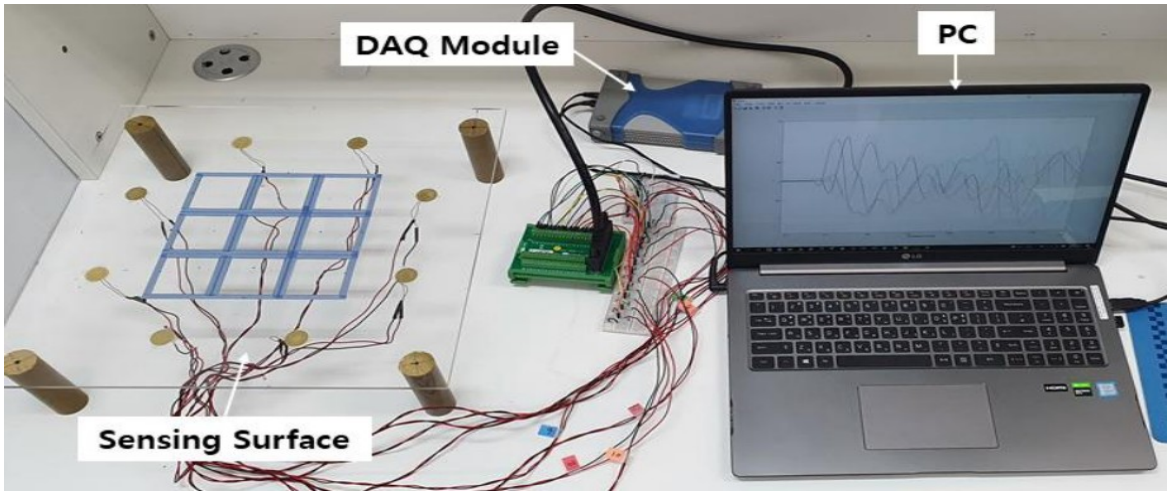


알고리즘을 이용한 위치 탐지 연구

1. 연구 배경







기계학습을 활용한 위치 탐지 연구

진동 데이터의 시간영역 특징 추출에 기반한 고장 분류 모델

- 시간 영역 통계적 특징

주기적 진동 , 고장 탐지

회전기기 설비의 예측정비를 위한 인공지능 기반의 진동 이상신호 패턴 분석 기법

- 시간 , 주파수 영역 특성 및 통계적 특징

주기적 진동 , 위치 탐지

바닥 진동을 통한 노인 낙상 검출

- 필터링 된 주파수 범위 (40~50Hz)

비주기적 진동 , 위치 탐지

기폭위치에 따른 주파수 분석

- 주파수 영역 특성 (주주파수)

비주기적 진동 , 위치 탐지

1. 연구 목표

시간 영역 특성과 통계적 특징

1	시간 영역 피크값
2	시간 영역 피크 시간
3	시간 영역 절대값평균
4	시간 영역 표준편차
5	시간 영역 P2P
6	시간 영역 RMS
7	시간 영역 왜도
8	시간 영역 첨도

주파수 영역 특성과 통계적 특징

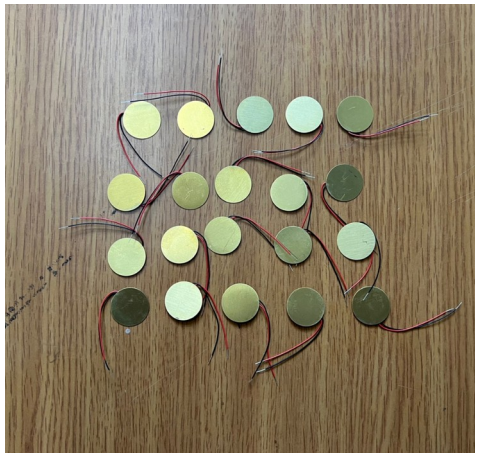
9	평균 주파수
10	주파수 영역 평균값
11	주파수 영역 표준편차
12	주파수 영역 왜도
13	주파수 영역 첨도
14	주파수 영역 파고율

센서 간 시간 차

15	시간 차 데이터

2. 실험 방법

2. 실험 장비 소개



피에조 센서



DAQ

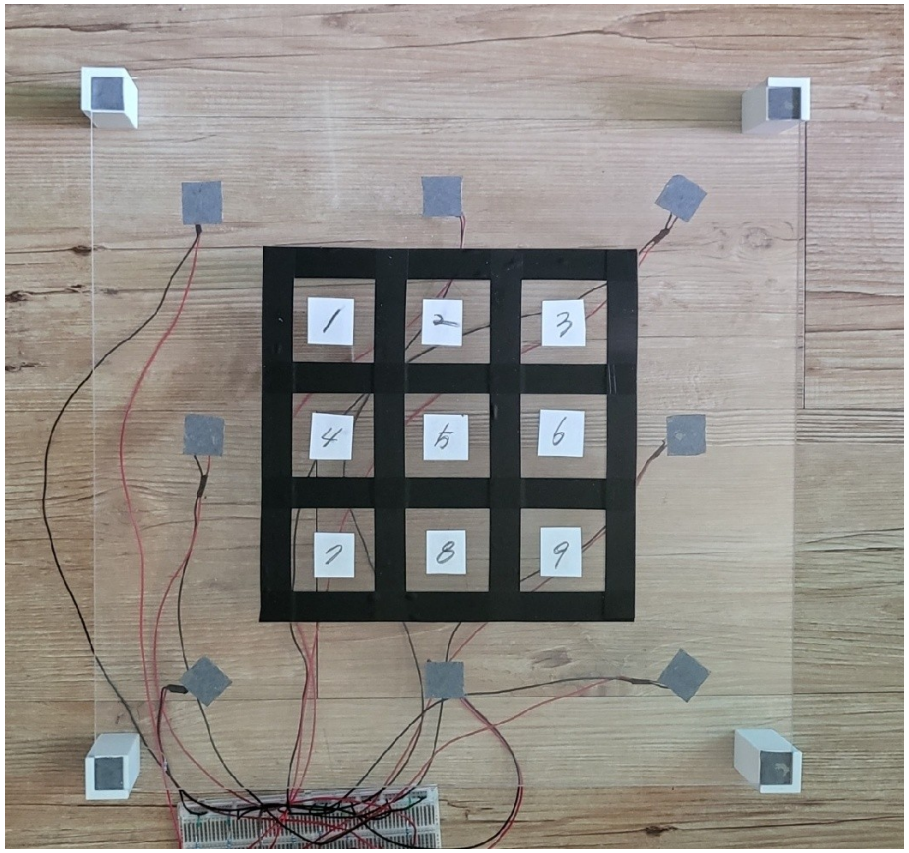


아크릴 판

MathWorks®

매트랩

2. 실험 장비 소개



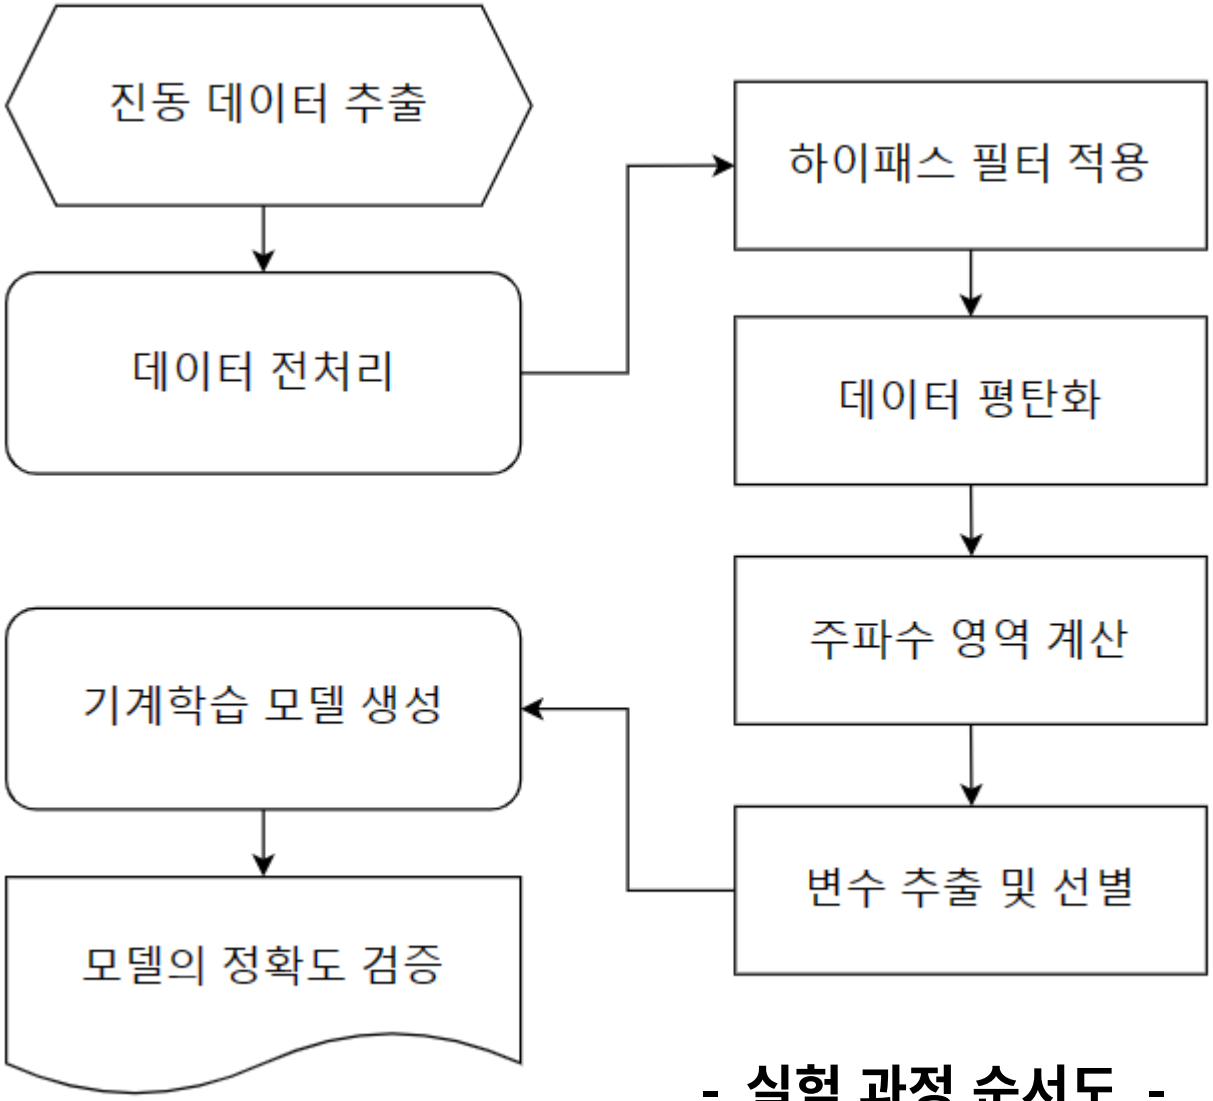
압전센서 (피에조 센서)

DAQ (USB6001)

매트랩

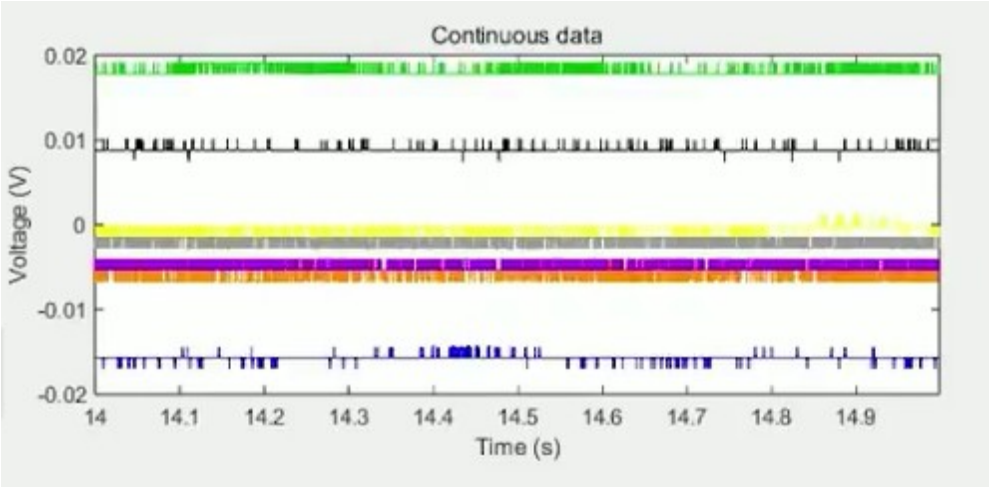
8 개의 센서

9 개의 위치

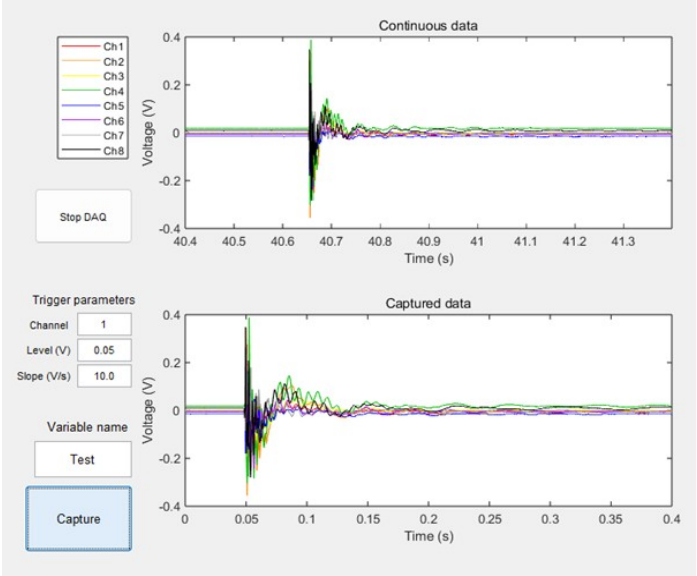

진동 데이터 추출
데이터 전처리
하이패스 필터 적용
데이터 평탄화
주파수 영역 계산
변수 추출 및 선별
기계학습 모델 생성
모델의 정확도 검증

- 실험 과정 순서도 -

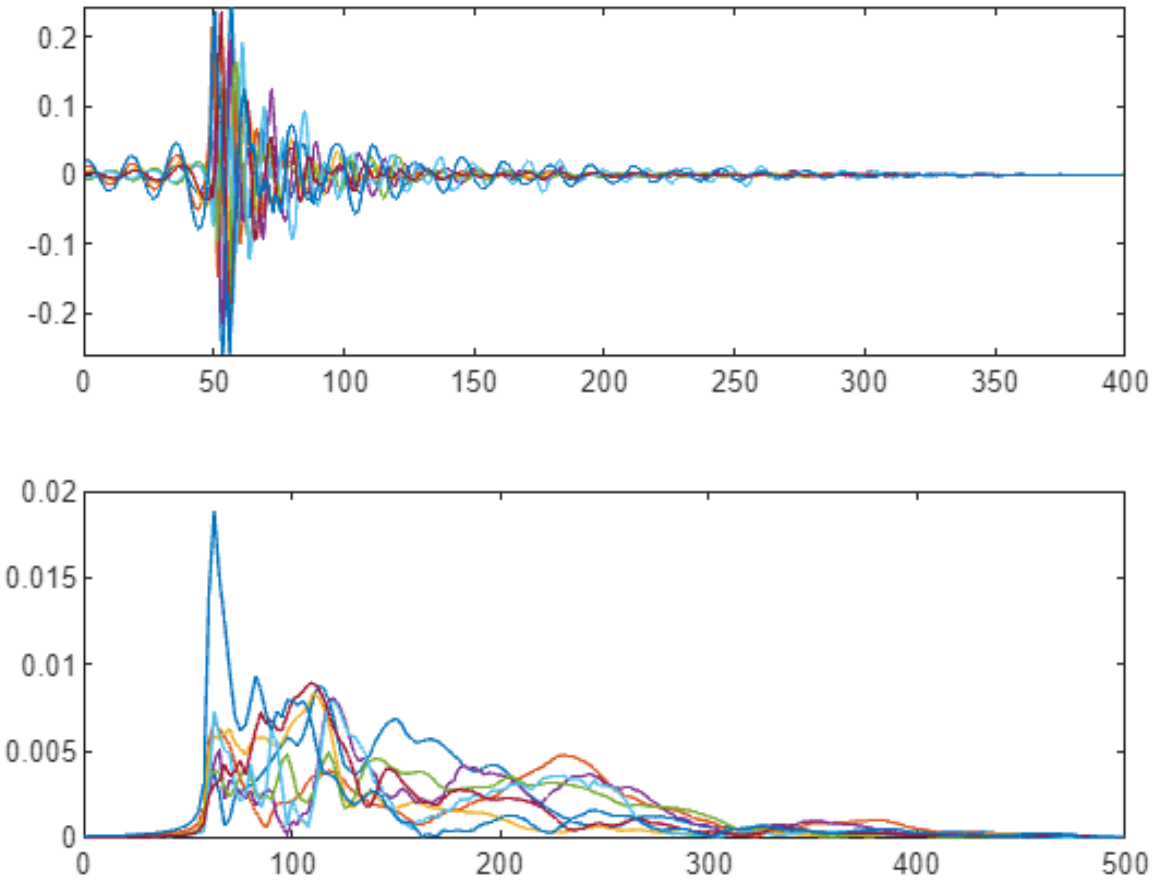
2. 데이터 추출



잡음이 섞인 초기 신호



샘플레이트 : 2500Hz
기록 시간 : 총 0.4 초 (1000 번)
트리거 방식 (트리거 이전 0.05 초)



61Hz 하이패스 필터와
데이터 평탄화를 적용한 결과

$Peak = Max(X_i)$	$Peak\ time = time\ of\ Max(X_i)$
$Absolute\ mean = \frac{1}{N}\sum_{i=1}^{N}\lvert X_i\rvert$	$Rms = \frac{\lVert X\rVert_\infty}{\sqrt{\frac{1}{N}\sum_{i=1}^{N}\lvert X_i\rvert^2}}$
$Standard\ deviation = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}\lvert X_i - \bar{X}\rvert^2}$	$Skewness = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{X_i - \bar{X}}{\sigma}\right)^3$
$Peak\ to\ Peak = Max(X_i) - Mix(X_i)$	$Kurtosis = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{X_i - \bar{X}}{\sigma}\right)^4$

시간 영역의 특성과 통계적 특징 : 8 개

2. 변수 추출 - 주파수 영역 변수

$Mean = \frac{1}{N}\sum_{i=1}^{N} X_i$	$Kurtosis = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{X_i - \bar{X}}{\sigma}\right)^4$
$Standard\ deviation = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}\lvert X_i - \bar{X}\rvert^2}$	$Crest\ factor = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\lvert X_i\rvert^2}$
$Skewness = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{X_i - \bar{X}}{\sigma}\right)^3$	$Mean\ freq = \sum_{i=1}^{N}(\boldsymbol{i} \times X_i) / \sum_{i=1}^{N}(X_i)$

주파수 영역의 특성과 통계적 특징 : 6 개

2. 데이터 정규화

$Max\ Abs$: 모든 데이터의 범위를 $[-1, 1]$로 조절

$$x_{new} = \frac{x}{|x|_{max}}$$



	Peak	PeakTime	AbsMeanT	StdT	P2pT	RmsT	SkewT	KurtosisT
1	0.99203	0.875	0.0087425	0.87491	1	0.87491	0.17467	1
2	0.81653	0.80921	0.0077033	0.65015	0.7193	0.65015	1	0.79502
3	0.75328	0.875	0.0083864	0.7215	0.75229	0.7215	0.25432	0.71781
4	0.81737	0.875	0.0088614	0.71359	0.81416	0.71359	-0.033773	0.78233
5	0.77972	0.92105	0.0075048	0.66047	0.73237	0.66047	-0.31429	0.82922
6	0.73021	1	0.011016	0.70374	0.62442	0.70374	0.88452	0.45805
7	0.89768	0.86842	0.0082297	0.80929	0.92515	0.80929	-0.0084288	0.84586
8	1	0.92105	0.015723	1	0.98838	1	-0.2255	0.50882

정규화 된 변수 (시간 영역)

2. 변수 선정

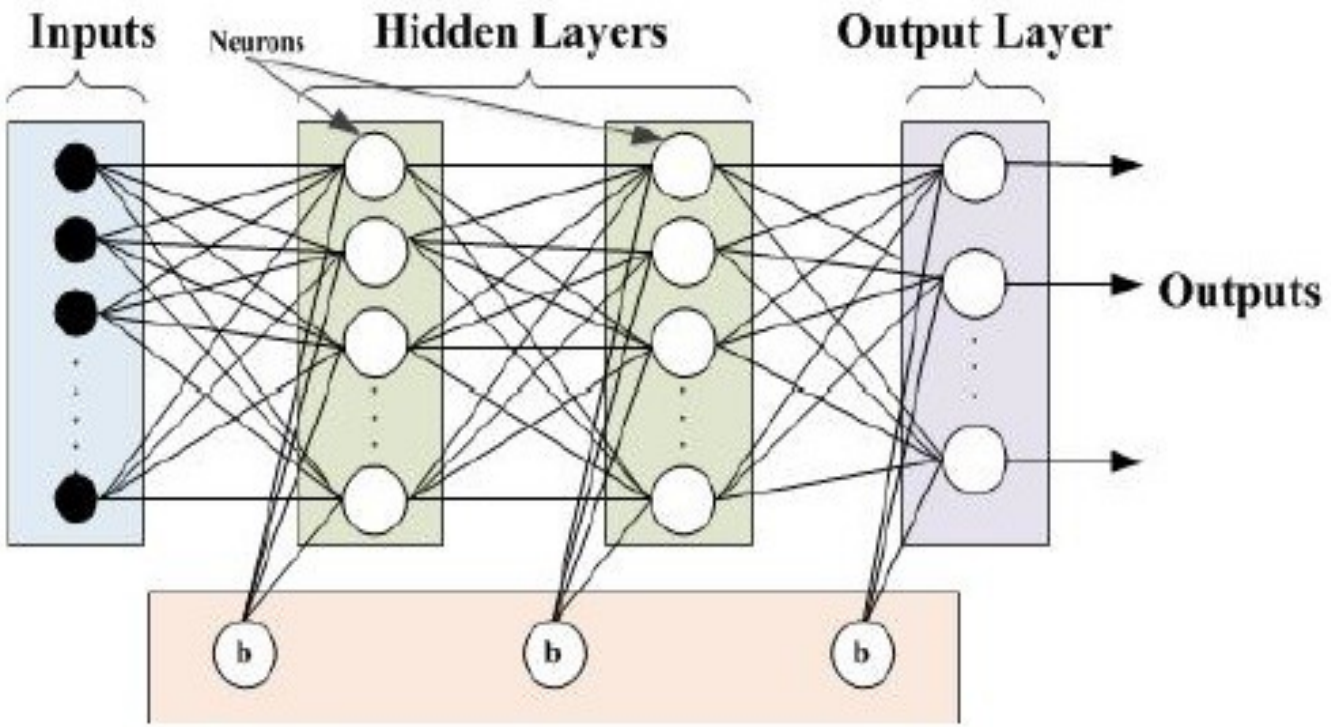
		Pvalue
1	시간 영역 피크값	2.2287e-194
2	시간 영역 피크 시간	3.5711e-238
3	시간 영역 절대값평균	5.8544e-92
4	시간 영역 표준편차	3.4372e-129
5	시간 영역 P2P	1.6537e-218
6	시간 영역 RMS	3.4317e-129
7	시간 영역 왜도	6.1613e-48
8	시간 영역 첨도	2.3283e-116
9	평균 주파수	1.4818e-156
10	주파수 영역 평균값	1.7302e-209
11	주파수 영역 표준편차	2.7383e-111
12	주파수 영역 왜도	6.5794e-07
13	주파수 영역 첨도	9.2906e-16
14	주파수 영역 파고율	1.3608e-32
15	시간 차 데이터	1.2179e-203

다중 선형회귀 모델을 통해 변수의 중요도 판단 및 선정

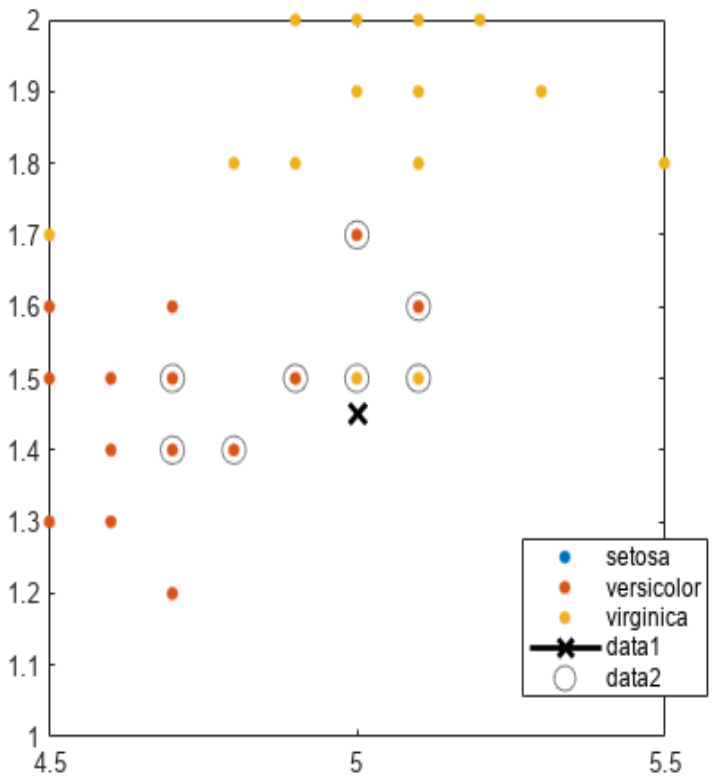
시간 영역 변수 : 상위 4 개 선별

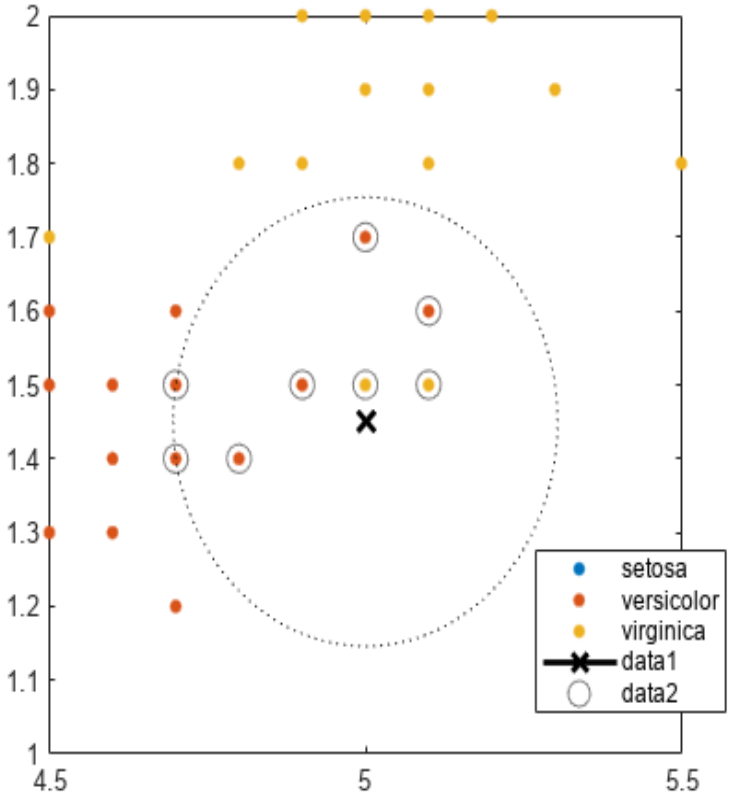
주파수 영역 변수 : 상위 3 개 선별

센서 간 시간 차 : 1 개

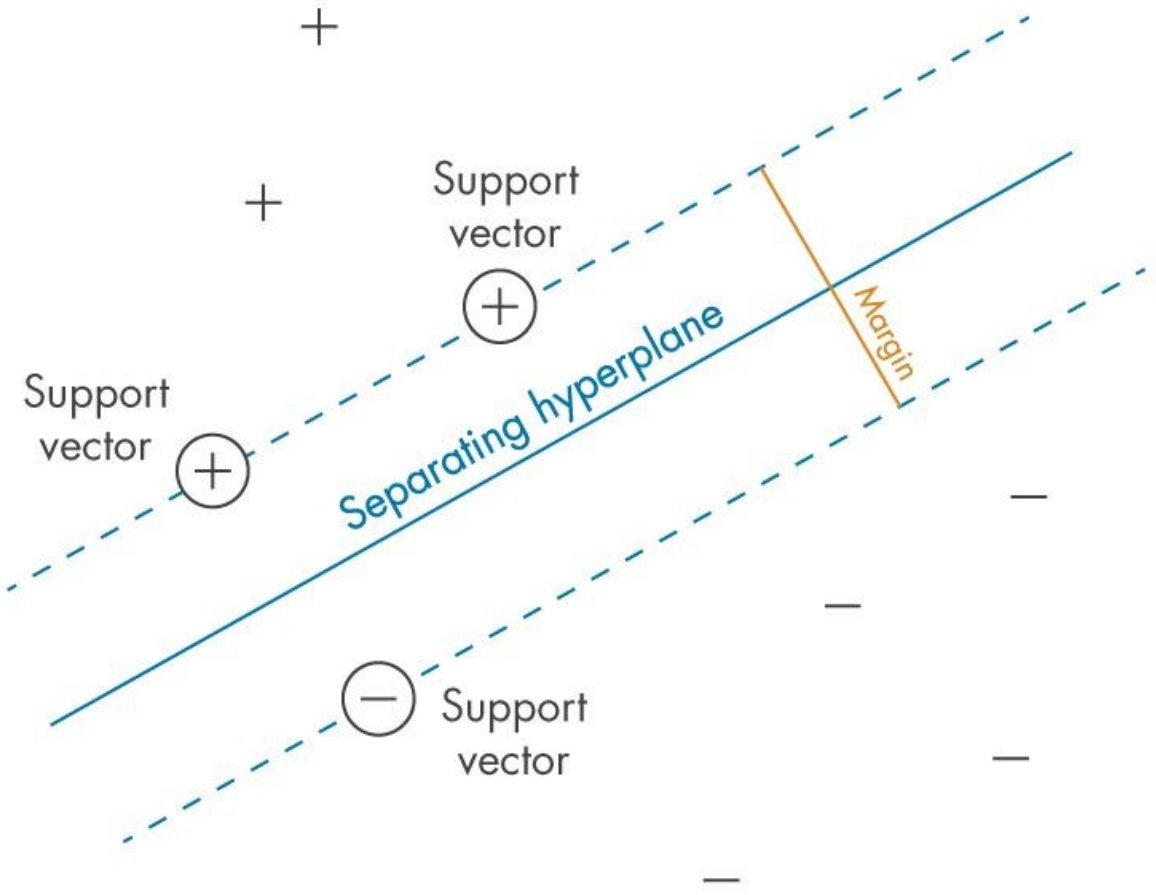


인공 신경망 (ANN)


2
1.9
1.8
1.7
1.6
1.5
1.4
1.3
1.2
1.1
1
4.5
5
5.5
setosa
versicolor
virginica
data1
data2

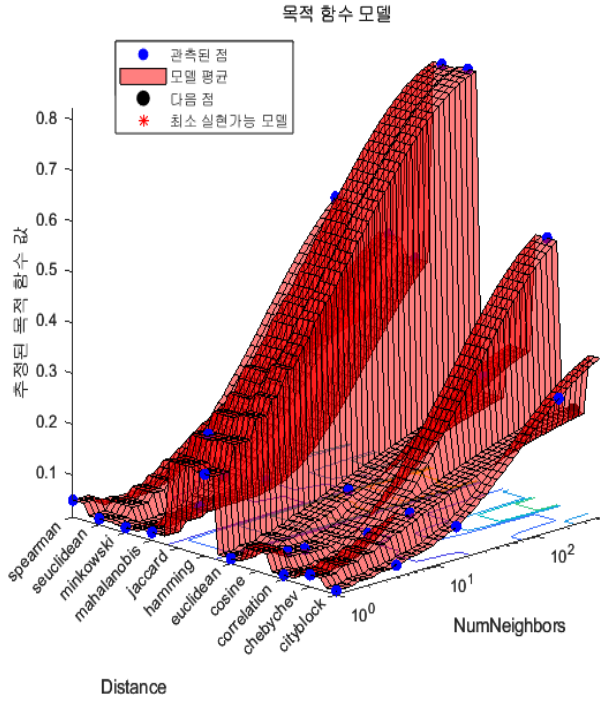

2
1.9
1.8
1.7
1.6
1.5
1.4
1.3
1.2
1.1
1
4.5
5
5.5
setosa
versicolor
virginica
data1
data2

K 최근접 이웃법 (KNN)

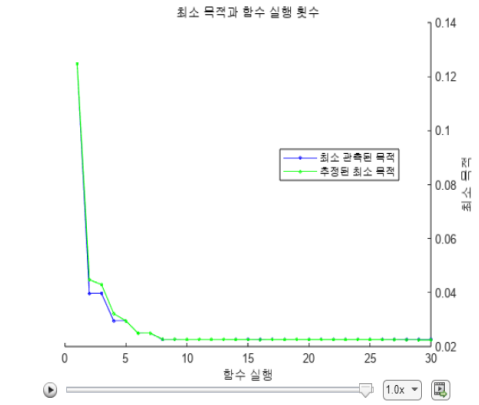

Support
vector
Support
vector
Separating hyperplane
Margin
Support
vector

서포트 벡터 머신 (SVM)

2. 기계학습 - 하이퍼 파라미터 최적화



Iter	Eval result	Objective	Objective runtime	BestSoFar (observed)	BestSoFar (estim.)	Coding	BoxConstraint
1	Best	0.12472	0.32213	0.12472	0.12472	onevsall	0.25297
2	Best	0.039683	0.52296	0.039683	0.044794	onevsall	677.61
3	Accept	0.048753	1.1257	0.039683	0.042971	onevsall	2.623
4	Best	0.029478	0.70321	0.029478	0.032201	onevsone	0.024265
5	Accept	0.035147	0.68715	0.029478	0.029506	onevsone	0.028868
6	Best	0.024943	0.6941	0.024943	0.024936	onevsone	0.0075041
7	Accept	0.17007	0.72544	0.024943	0.02495	onevsone	0.0017077
8	Best	0.022676	0.72511	0.022676	0.022753	onevsone	0.020963
9	Accept	0.12132	0.30605	0.022676	0.022743	onevsall	127.21
10	Accept	0.054422	0.6914	0.022676	0.022673	onevsone	0.01206
11	Accept	0.022676	0.69603	0.022676	0.022668	onevsone	0.0058934
12	Accept	0.048753	1.111	0.022676	0.02268	onevsall	880.16
13	Accept	0.15986	0.7271	0.022676	0.022673	onevsone	0.0059835



최적화가 완료되었습니다.
MaxObjectiveEvaluations 30회에 도달했습니다.
총 함수 실행 횟수: 30
총 경과 시간: 12.1813초
총 목적 함수 실행 시간: 1.4968

KNN

최선의 관측된 실현가능점:

NumNeighbors	Distance
1	cityblock

관측된 목적 함수 값 = 0.024943
추정된 목적 함수 값 = 0.024978
함수 실행 시간 = 0.040052

최선의 추정된 실현가능점(모델에 따라 다름):

NumNeighbors	Distance
1	correlation

추정된 목적 함수 값 = 0.024941
추정된 함수 실행 시간 = 0.034676

최적화가 완료되었습니다.
MaxObjectiveEvaluations 30회에 도달했습니다.
총 함수 실행 횟수: 30
총 경과 시간: 30.7824초
총 목적 함수 실행 시간: 22.3649

SVM

최선의 관측된 실현가능점:

Coding	BoxConstraint	KernelScale
onevsone	0.020963	0.0091595

관측된 목적 함수 값 = 0.022676
추정된 목적 함수 값 = 0.022425
함수 실행 시간 = 0.72511

최선의 추정된 실현가능점(모델에 따라 다름):

Coding	BoxConstraint	KernelScale
onevsone	0.010099	0.0054024

추정된 목적 함수 값 = 0.022455
추정된 함수 실행 시간 = 0.70005

3. 연구 결과

3. 실험 결과 - 변수의 정확도 비교

시간 영역 변수를 이용한 모델의 정확도

	선택된 변수	변수의 수	ANN - 생성	KNN - 생성	SVM - 생성	ANN - 테스트	KNN - 테스트	SVM - 테스트
1	"1, 2, 5, 6"	4	98.073	100	100	94.18	96.296	97.619

주파수 영역 변수를 이용한 모델의 정확도

	선택된 변수	변수의 수	ANN - 생성	KNN - 생성	SVM - 생성	ANN - 테스트	KNN - 테스트	SVM - 테스트
1	"9, 10, 11"	3	99.433	100	100	96.561	97.884	98.413

센서 간 시간 차를 이용한 모델의 정확도

	선택된 변수	변수의 수	ANN - 생성	KNN - 생성	SVM - 생성	ANN - 테스트	KNN - 테스트	SVM - 테스트
1	15	1	69.955	100	77.551	67.989	90.741	71.693

위치 당 140 번의 실험 (총 1260 번)

학습과 검증의 비율을 7 : 3 으로 함
(140 번 중 랜덤으로 선별)

3. 실험 결과 - **센서 간 시간 차** KNN 의 혼동행렬



센서 간 시간 차를 이용한 KNN 의 혼동행렬

3. 실험 결과 - 시간 영역 KNN 의 혼동행렬



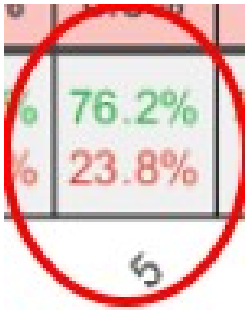
시간 영역 변수를 이용한 KNN 의 혼동행렬

3. 실험 결과 - 주파수 영역 KNN 의 혼동행렬



주파수 영역 변수를 이용한 KNN 의 혼동행렬

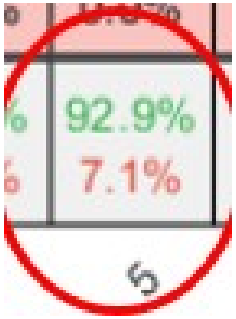
3. 실험 결과 - KNN 모델에서의 **5 번 위치 정확도**



센서 간 시간 차
5 번 위치 정확도

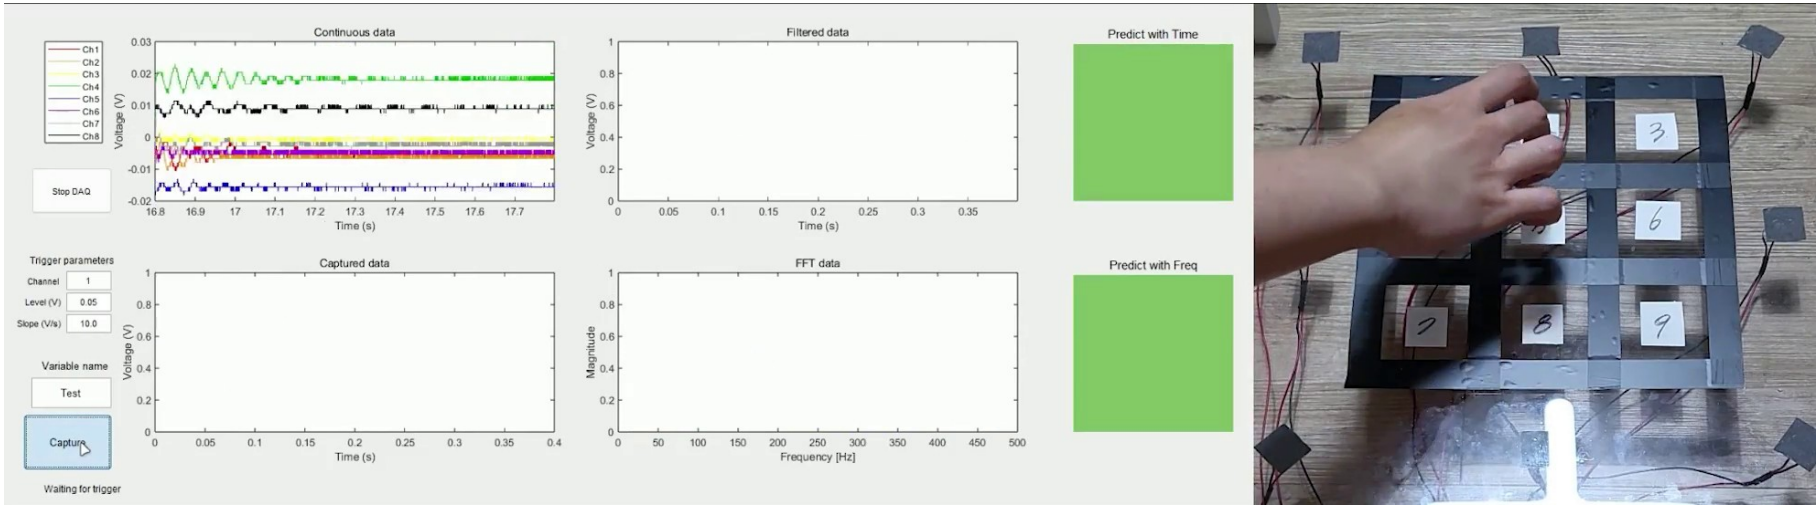


시간 영역
5 번 위치 정확도



주파수 영역
5 번 위치 정확도

3. 실시간 예측



실시간으로 위치를 예측하는 모습
(1.5 배속)

1. 시간 영역과 주파수 영역의 특성과 통계적 특징을 사용하여 노크 위치를 탐지 할 수 있다 .

2. 센서 간 시간 차만을 사용한 방식보다 시간 영역과 주파수 영역의 특성과 통계적 특징을 사용한 방식의 정확도가 더 높음을 확인했다 .

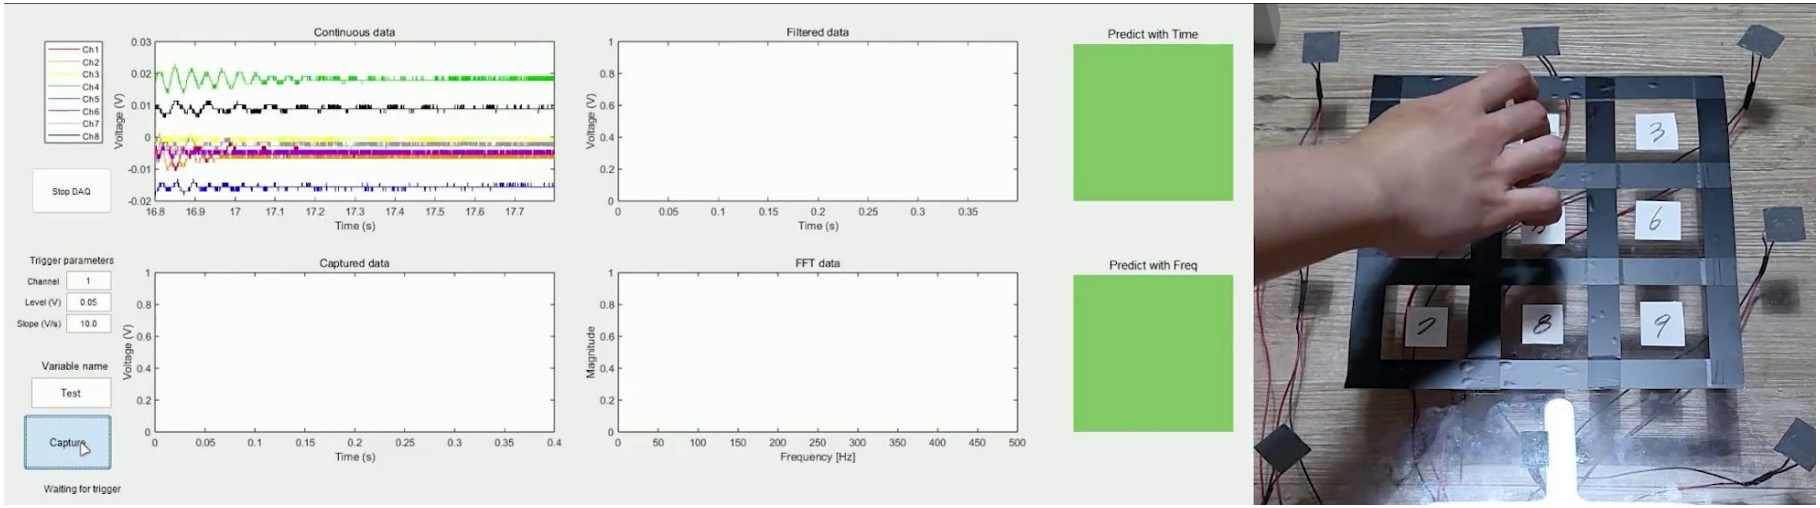
3. 실시간 예측을 통해 직접 정확도와 문제를 확인 할 수 있다 .

참고 문헌

1. A System for Tracking and Characterizing Acoustic Impacts on Large Interactive Surfaces - Nisha Checka
2. Directional piezoelectric phased array filters for detecting damage in isotropic plates - A S Purekar
3. Knock sensing and imaging from structural bending waves - 정아람 , 손성호
4. 기계장비 진동 데이터를 이용한 딥러닝 기반의 고장 분류 모델 - 이수형
5. 기폭위치에 따른 주파수 분석 - 손석범
6. 노크 인터랙션을 이용한 인터랙티브 쇼윈도 - 전혜선
7. 루프센서와 피에조센서를 이용한 차량정보 수집장비 개발 연구 - 민중홍
8. 바닥 진동을 통한 노인 낙상 검출 - 김동완
9. 인공 신경망을 이용한 손상 추정을 위한 최적 센서 위치 선정 - 김미진
10. 주파수 영역의 통계적 특징과 인공신경망을 이용한 기계가공의 사운드 모니터링 시스템 - 이경민
11. 진동 데이터의 시간영역 특징 추출에 기반한 고장 분류 모델 - 김승일
12. 회전기기 설비의 예측정비를 위한 인공지능 기반의 진동 이상신호 패턴 분석 기법 - 이제동

Q & A

3. 실시간 예측



실시간으로 위치를 예측하는 모습
(1.5 배속)